

2023 年第三届长三角高校数学建模竞赛

题 目 基于 TOPSIS 和 ARIMA 模型的考研难度分析

摘要:

随着我国现代化进程的不断加深、就业人群中高学历人数逐年增加,我国人才市场出现了学历挤兑、高端人才短缺等情况,学历的重要性越来越明显,越来越多的本、专科毕业生选择参加研究生考试升学。本课题量化分析了 2023 年考研难度,提出了影响考研难度的一些主要因素;同时研究了 1979 年以来至今的考研难度的变化趋势,给出了近 3 年考研难度最大的 10 所学校以及 10 个专业;并且结合研究结论,对 2024 年考研形势做出了评估。

针对问题一:我们收集了 2023 年的考研数据,选用熵值法计算数据中的各因素权重,提出导致考研难的主要因素有:报考人数、录取人数、最低分数线和推免人数。熵值法从信息的离散程度衡量因素对于总体的影响程度,能够对因素的重要性进行客观、准确的权重分析。

针对问题二:我们收集了 1979 年至今的考研数据,结合 TOPSIS 优劣解距离模型和熵值法,对 45 年间考研难度的变化趋势做了三种情况的计算排序。我们认为 2023 年考研不是“最难的”,近 3 年考研难度最大的 10 所学校分别为:南京大学、中国人民大学、中国科学技术大学、复旦大学、浙江大学、上海交通大学、南开大学、北京大学、清华大学、中国科学院大学,考研难度最大的 10 个专业分别为:应用心理、建筑学、会计、电气工程、翻译硕士、计算机科学与技术、金融、自动化、汉语言文学、应用统计。通过 TOPSIS 法进行组内综合评价,能充分利用原始数据的信息,其结果能精确地反映各评价方案之间的差距,并且对数据分布和样本含量没有严格限制,计算简单易行。

针对问题三:我们使用 ARIMA 时间序列分析模型预测了未来三年的考研数据,将数据代入 TOPSIS 优劣解距离模型预测了未来三年的考研难度趋势。通过结合时间序列分析和组内综合评价,模型结论更为可靠、预测精度更为准确、数据解释更为贴切、适用范围更为广泛。基于预测结论,我们认为 2024 年的考生应当着重关注:酌情选择报考专业硕士,合理甄选报考专业、谨慎评估跨考难度,扩大目标高校范围、“逆向考研”普通高校,综合研判就业形势、放弃考研选择就业四个方面。

最后,我们评估了模型的优势,讨论了模型的不足之处,并提出了改进模型的一些可行措施。

关键词:熵值法 TOPSIS ARIMA

目录

一、 问题重述..... 1

1.1 问题背景 1

1.2 问题提出 1

1.3 问题分析 1

二、 模型的假设与理由..... 2

三、 定义与符号说明..... 2

四、 模型的建立与求解..... 2

4.1 问题 1 的模型建立与求解 2

4.1.1 数据预处理 2

4.1.2 模型的建立 3

4.1.3 问题 1 的求解 4

4.2 问题 2 的模型建立与求解 7

4.2.1 数据预处理 7

4.2.2 模型的建立 8

4.2.3 问题 2 的求解 11

4.3 问题 3 的模型建立与求解 11

4.3.1 模型的建立 11

4.3.2 问题 3 的求解 7

五、 模型的分析检验..... 15

六、 模型的评价与改进..... 16

6.1 评估 16

6.1.1 优点 16

6.1.2 缺点 16

6.2 改进 16

七、 参考文献..... 17

八、 附录..... 18

一、 问题重述

1.1 问题背景

如今，大学生面临的就业压力越来越大。一方面，我国人才市场逐渐呈现供大于求的饱和状态；另一方面，高端人才市场仍呈“蓝海”，急需各行各业“高精尖”人才进一步推动我国的现代化进程。多方面的因素促使越来越多的大学生考研热情高涨，2023年考研报名人数更是创下了 474 万人的历史新高。

然而，疫情导致的经济下行、就业岗位缩减、高学历人群增多带来的学历挤兑、就业岗位对学历要求水涨船高等等问题，使得考研难度逐年上涨、居高不下。

全面建设社会主义现代化国家需要培养、造就大批德才兼备的高层次人才，其中，研究生教育肩负着高层次人才培养和创新、创造的重要使命。

但是，考研并不适合每一个人，如何理性评估考研难度、合理选择考研、避免“考研”成为某种“路径依赖”成为了亟待解决的重要课题。

1.2 问题提出

- **问题 1:** 选择合适的权重计算方法，将收集的 2023 年考研数据处理计算，得到符合实际的权重分配方式，进而对 2023 年考研难度做出评价。
- **问题 2:** 基于问题 1 的研究方法，选择合适的综合评价模型，对 1979 年至 2023 年考研难度趋势进行分析，并由此进一步评选“十大考研最难院校”和“十大考研最难专业”。
- **问题 3:** 使用模型预测未来 3 年考研难度的变化，基于我们预测的结论，给出 2024 年广大考生的考研建议。

1.3 问题分析

- **问题 1:** 首先需要我们收集考研数据，然后选择与考研难度紧密相关的指标，查找并清洗数据。基于处理后的数据建立综合评价模型，从而判断导致 2023 年考研难的主要原因。
- **问题 2:** 收集 1979 年至 2023 年的考研数据，通过 TOPSIS 法进行组内综合评价，充分利用原始数据的信息，由此进一步评选出“十大考研最难院校”和“十大考研最难专业”。
- **问题 3:** 参考问题 1 和问题 2 数据分析的结果，运用 ARIMA 时间序列分析模型预测的方法，对报考 2024 年研究生的广大考生提出积极有效建议。

二、模型的假设与理由

- **假设 1:** 假设收集到的考研数据真实可靠。
- **理由 1:** 由于历史久远、数据不清等多方面的原因，考研数据存在数据缺失、多个版本间互不相同等问题，选择中国教育部发布的权威数据，忽略其余版本数据，对于厘清数据、简化问题有着至关重要的作用。
- **假设 2:** 假设忽略政策变化、天灾人祸等不可控因素或难以量化的因素对考研难度的影响。
- **理由 2:** 疫情问题、经济下行、学历贬值、高校扩招等原因对考研难度也有着不同程度的影响，这些因素难以量化、非人为可控，忽略这些因素有助于建立更准确、更广泛适用的研究模型。

三、定义与符号说明

本文使用的关键数学符号如表 1 所示。

表 1:本文使用的符号

序号	符号	含义
1	e	信息熵值
2	d	信息效用值
3	D^+	正理想解距离
4	D^-	负理想解距离
5	X	矩阵
6	i	第 <i>i</i> 个方案
7	j	第 <i>j</i> 个指标
8	P	因素所占权重
9	g	差异系数
10	W	权数
11	S_i	综合得分
12	Z	标准化矩阵
13	G	欧几里得距离
14	c	常数
15	$\alpha, \varepsilon, \beta$	

四、模型的建立与求解

4.1 问题 1 的模型建立与求解

4.1.1 数据预处理

我们从中国教育部网站^[4]收集了 2023 年研究生报考、录取人数统计数据（不含博士生），制表如下：

表 2:2023 年全国研究生数据表

报考人数（万人）	录取人数（万人）	最低分数线（分）	推免人数（万人）
474	118.5	251	42.3237

过去三年中，疫情反复下就业压力骤升，让大量往届生和在职人群选择考研。2023 年全国硕士研究生报考人数达 474 万人，相比 2022 年上涨了 17 万人，增速为 3.72%，再创历史新高；而 2023 年录取人数达 118.5 万人，相比 2022 年增加了 8.15 万人，增速为 7.39%。

4.1.2 模型的建立

为了客观衡量 2023 年数据中各指标对综合评价的影响，我们使用了熵值法对数据进行处理。熵值法反映了指标的离散程度，是一种客观赋权的方法。在评价指标体系中，指标取值差异越大的指标，也就是越难以实现的指标，这样的指标更能反映被评价单位的差距。

$$A = \begin{pmatrix} X_{11} & \cdots & X_{1m} \\ \vdots & \vdots & \vdots \\ X_{m1} & \cdots & X_{nm} \end{pmatrix}_{n \times m} \quad \text{其中 } X_{ij} \text{ 为第 } i \text{ 个方案第 } j \text{ 个指标的数值} \quad (1)$$

对于越大越好的指标：

$$X'_{ij} = \frac{X_{ij} - \min(X_{1j}, X_{2j}, \cdots, X_{nj})}{\max(X_{1j}, X_{2j}, \cdots, X_{nj}) - \min(X_{1j}, X_{2j}, \cdots, X_{nj})} + 1, \quad (2)$$

$i = 1, 2, \cdots, n; j = 1, 2, \cdots, m$

对于越小越好的指标：

$$X'_{ij} = \frac{\max(X_{1j}, X_{2j}, \cdots, X_{nj}) - X_{ij}}{\max(X_{1j}, X_{2j}, \cdots, X_{nj}) - \min(X_{1j}, X_{2j}, \cdots, X_{nj})} + 1, \quad (3)$$

$i = 1, 2, \cdots, n; j = 1, 2, \cdots, m$

为了方便起见，仍记非负化处理后的数据为 X_{ij}
计算第 j 项指标下第 i 个方案占该指标的比重：

$$P_{ij} = \frac{X_{ij}}{\sum_{i=1}^n X_{ij}} \quad (j = 1, 2, \cdots, m) \quad (4)$$

计算第 j 项指标的熵值：

$$e_j = -k^* \sum_{i=1}^n P_{ij} \log(P_{ij}) \quad (5)$$

其中 $k>0, \ln$ 为自然对数, $e_j \geq 0$ 。式中常数 k 与样本数 m 有关, 一般令 $k = 1/\ln_m$, 则 $0 \leq e \leq 1$ 。

计算第 j 项指标的差异系数:

对于第 j 项指标, 指标值 X_{ij} 的差异越大, 对方案评价的作用越大, 熵值就越小, $g_j = 1 - e_j$, 则 g_j 越大指标越重要。

求权数:

$$W_j = \frac{g_j}{\sum_{j=1}^m g_j}, j = 1, 2 \cdots m \quad (6)$$

计算各方案的综合得分:

$$S_i = \sum_{j=1}^m W_j * P_{ij} (i = 1, 2, \cdots n) \quad (7)$$

熵值法计算得到的权重结果如下:

表 3: 指标权重计算

项	信息熵值 e	信息效用值 d	权重 (%)
录取人数 (万人)	0.673	0.327	47.152
报考人数 (万人)	0.873	0.127	18.314
最低国家分数线 (学硕)	0.88	0.12	17.331
推免名额 (万人)	0.881	0.119	17.202

4.1.3 问题 1 的求解

由于我们选取的评价指标中, 存在正向、负向两类的不同指标, 因此我们选用了 TOPSIS 优劣解距离法, 根据熵值法计算得出的权重, 进一步计算综合得分指数, 衡量 2023 年度考研难度。TOPSIS 法是 C.L.Hwang 和 K.Yoon 于 1981 年首次提出, 根据有限个评价对象与理想化目标的接近程度进行排序。

将指标分为四类, 如下表所示:

表 4: 指标分类图

指标名称	指标特点
极大型 (效益型) 指标	越大 (多) 越好
极小型 (成本型) 指标	越小 (少) 越好
中间型指标	越接近某个值越好
区间型指标	落在某个区间最好

在处理数据时, 有些指标的数据越大越好, 有些则是越小越好, 有些又是中间某个值或者某段区间最好。我们可以对其进行“正向化处理”, 使指标都可以像考试分数那样, 越大越好。

正向化处理, 就是将上述的四种指标数据进行处理, 将其全部转化为极大型指标数

据。

为了消除不同的数据指标量纲的影响，我们还有必要对已经正向化的矩阵进行标准化。在概率统计中，标准化的方法一般是 $\frac{X - EX}{\sqrt{DX}}$ ，不过这里我们不采用。记标准化后

的矩阵为 Z ，其中 $Z_{ij} = \frac{x_{ij}}{\sqrt{\sum_{i=1}^n x_{ij}^2}}$ ，也就是 $\frac{\text{每一个元素}}{\sqrt{\text{其所在列的元素的平方和}}}$ 。

对数据进行了相应的处理后，可以用 Z_i 来表达第 i 个方案。假设有 n 个待评价的方案， m 个指标，此时 $Z_i = [Z_{i1}, Z_{i2}, \dots, Z_{im}]$ 。由这 n 个向量构成的矩阵也就是我们的标准化矩阵 Z 了：

$$Z = \begin{bmatrix} z_{11} & z_{12} & \cdots & z_{1m} \\ z_{21} & z_{22} & \cdots & z_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ z_{n1} & z_{n2} & \cdots & z_{nm} \end{bmatrix} \quad (8)$$

经过了正向化处理和标准化处理的评分矩阵 Z ，里面的数据全部是极大型数据。我们就可以从中取出理想最优解和最劣解。取出每个指标，即每一列中最大的数，构成理想最优解向量，即

$$z^+ = [z_1^+, z_2^+, \dots, z_m^+] = [\max\{z_{11}, z_{21}, \dots, z_{n1}\}, \dots, \max\{z_{12}, z_{22}, \dots, z_{n2}\}, \dots, \max\{z_{1m}, z_{2m}, \dots, z_{nm}\}] \quad (9)$$

同理，取每一列中最小的数计算理想最劣解向量：

$$z^- = [z_1^-, z_2^-, \dots, z_m^-] = [\min\{z_{11}, z_{21}, \dots, z_{n1}\}, \dots, \min\{z_{12}, z_{22}, \dots, z_{n2}\}, \dots, \min\{z_{1m}, z_{2m}, \dots, z_{nm}\}] \quad (10)$$

其中 z^+ 就是 $z_{\max}$ ， z^- 就是 $z_{\min}$ 。

在得到理想最优解和理想最劣解的基础上就能计算每个方案的评分了。根据上面的距离评分公式：

$$\frac{Z_i - Z_{\min}}{Z_{\max} - Z_{\min}} \quad (11)$$

对其进行变型，也就是：

$$\frac{Z_i - Z_{\min}}{(Z_{\max} - Z_{\min}) + (Z_i - Z_{\min})} \quad (12)$$

变型的目的是为了使用欧几里得距离来衡量两个方案的距离，变形前后分母的计算结果其实是不同的。这样更能体现出是综合距离。否则所有方案计算得分时分母都是相同的，相当于只衡量了分子，也就是距离最劣解的距离。

于是计算距离评分：

对于第*i*个方案 z_i ，我们计算它与最优解的距离：

$$G_i^+ = \sqrt{\sum_{j=1}^m (z_j^+ - z_{ij})^2} \quad (13)$$

与最劣解的距离：

$$G_i^- = \sqrt{\sum_{j=1}^m (z_j^- - z_{ij})^2} \quad (14)$$

定义第*i*个方案的评分为 S_i ：

$$S_i = \frac{d_i^-}{d_i^+ + d_i^-} \quad (15)$$

$0 \leq S_i \leq 1$ ，且 d_i^+ 越小，也就是该方案与最优解的距离越小时， S_i 越大；相应的， d_i^- 越小，也就是该方案与最劣解的距离越小时， S_i 越小。为同时兼顾了该方案与最优解与最劣解的距离的评分。

最终我们得到 2023 年 TOPSIS 评价法的计算结果为：

表 5: TOPSIS 评价法计算结果


年份	正理想解距离 (D+)	负理想解距离 (D-)	综合得分指数
2023 年	0.72695894	0.68667346	0.48575108

综上所述,通过 TOPSIS 法对 2023 年考研难度计算得到的综合得分约为 0.48575108。导致 2023 年度“考研难”的主要因素有：报考人数再创新高、录取人数提升幅度相对较小、最低国家分数线变化不大、推免人数上涨较多等。除此之外，新冠疫情带来的健康问题、经济低迷导致的岗位减少、高学历人数增多导致的学历挤兑、考研人数一再增加而引起的“逆向考研”等较难以量化的因素，也对 2023 年考研难度产生了一定的影响。

4.2 问题 2 的模型建立与求解

4.2.1 数据预处理


我们从中国教育在线^[3]收集了 1979 年至 2023 年研究生考试数据,包含:报考人数、报考增速、录取人数、录取增速、报录比、最低分数线、推免人数。其中,报考人数和录取人数制图如下:




图表 1 报考、录取人数折柱图

自 1979 年以来,报考人数连年上涨,增幅最大超过 36%,增速中位数为 11%;录取人数增速最大为 10.43%,增速中位数为 6.7%,不及报考人数增长水平;报录比最大值为 11.889,中位数为 3.588,平均值为 4.065,侧面说明了考研难度越来越高、竞争压力越来越大。


为了评价各大院校的考研难度,我们从中国大学生在线^[3]收集了考研最难排行榜上的前四十位大学的考研数据,制图如下:




图表 2 21 年报考人数 (万) 散点图



图表 3 21 年推免率散点图




图表 4 21 年复试比例（最高值）散点图




图表 5 21 年初试成绩占比散点图

近三年来，不同院校“报考人数”差距较大，最大值为 4.31 万人，最小值仅为 0.7 万人，中位数为 2.175 万人。不同院校的“推免率”同样差距较大，一般地，学校教学实力、研究实力越强，推免率就越高；在这一因素中，数据峰度达到了 2.621，推免率最高的学校与推免率最低的学校甚至存在近五倍的差距。大部分院校的“复试比例”稳定在 1-1.2，极个别院校达到了 1.5 甚至 1.7，侧面显示出个别院校的考研热度和竞争压力。而“初试成绩占比”则以 0.7 居多，位于我国西南部地区的大学也存在取值为 0.5 或 0.6 的分布情况。


为了评价各个专业的考研难度，我们从中国大学生在线^[3]收集了专业考研数据，制图如下：



图表 6 21 年分数线箱型图



图表 7 21 年报录比箱型图




图表 8 复试比例箱型图

以 2021 年考研各专业的数据为例：考研分数中位数为 339，分布范围为 69-407 分，不同专业的分数线差别很大；报录比中位数为 10，分布范围为 1.3-58.675，75%分位数为 28，说明不同专业的竞争水平也有所不同，热门专业报录比一般在 10 以上；复试比例中位数为 1.2，最大值达到 1.7，分布较为稳定，大部分专业的复试比例都在 1.2 左右。

4.2.2 模型的建立

为了研究 1979 年以来全国硕士研究生考试的难度变化趋势，我们使用 TOPSIS 方法对收集数据进行了计算并绘图。由于部分数据年代久远无法查证、部分数据存在多个版本并不相同等情况，我们分别做了三种情况的趋势图，如下：



其中，2 因素指的是：报考人数、录取人数；3 因素则在 2 因素的基础上增加了最低国家分数线；4 因素是在 3 因素的基础上增加了推免人数。1979 年以来考研难度整体呈现不断上涨趋势，并在 2009 年和 2019 年有较大幅度的上涨趋势。

基于考研难度的研究方法和 TOPSIS 评价模型，我们选取了四种因素评价考研难度最大的学校，分别为：报考人数、推免率、复试比例和初试成绩占比。

表 6: 指标权重计算结果

项	信息熵值 e	信息效用值 d	权重 (%)
21 年报考人数 (万)	0.96	0.04	5.781
21 年推免率	0.948	0.052	7.452
21 年复试比例 (最高值)	0.929	0.071	10.214
22 年报考人数 (万)	0.957	0.043	6.235
22 年推免率	0.948	0.052	7.489
22 年复试比例 (最高值)	0.962	0.038	5.444
23 年报考人数 (万)	0.965	0.035	5.084
23 年推免率	0.954	0.046	6.547
23 年复试比例 (最高值)	0.972	0.028	3.983
21 年初试成绩占比	0.854	0.146	21.066
22 年初试成绩占比	0.863	0.137	19.706
23 年初试成绩占比	0.993	0.007	0.998

图表说明：上表展示了熵权法的权重计算结果，根据结果对各个指标的权重进行分析。

每年度的“报考人数”因素的权重维持在 5%-6% 左右，而每年度的“推免率”因素的权重则上涨了 1%-2%，近三年来知名高校推免率不断提高，挤压了考研学生的名额，是造成该因素权重上涨的主要原因。每年度的“复试比例”因素的权重则持续走低，这是因为不同大学近三年的复试比例都较为稳定，所以降低了在使用熵权法的 TOPSIS 模型中的评价权重。在整个评价模型中权重占比最高的是“初试成绩占比”因素，不同学校、不同专业的初试成绩占比有较大差异，一般认为初试成绩占比越大的学校，复试带来的不稳定性越小，对于考研学生的难度越低。

使用上述四种因素的 TOPSIS 评价模型得出的学校考研难度排名结果如下：

表 7:TOPIS 评价法计算结果

索引值	综合得分指数	排序
南京大学	0.59837989	1
中国人民大学	0.59098052	2
中国科学技术大学	0.55341932	3
复旦大学	0.53852649	4
浙江大学	0.52027278	5
上海交通大学	0.50448986	6
南开大学	0.46207842	7
北京大学	0.43155581	8
清华大学	0.40659243	9
中国科学院大学	0.39683558	10

基于学校考研难度评价模型和 TOPSIS 评价模型，我们从上述十大考研最难的学校官网获取了各个学院、专业的数据，并设计了三个因素用于评价考研难度最大的专业，分别为：分数线、报录比、复试比例。

使用熵权法对专业数据进行指标权重计算，制表如下：

表 8:指标权重计算结果

项	信息熵值 e	信息效用值 d	权重(%)
21 年分数线（最高值）	0.977	0.023	1.453
21 年报录比	0.899	0.101	6.289
21 年复试比例（最高值）	0.577	0.423	26.346
22 年分数线（最高值）	0.977	0.023	1.441
22 年报录比	0.9	0.1	6.215
22 年复试比例（最高值）	0.577	0.423	26.346
23 年分数线（最高值）	0.977	0.023	1.411
23 年报录比	0.9	0.1	6.238
23 年复试比例（最高值）	0.611	0.389	24.26

图表说明：上表展示了熵权法的权重计算结果，根据结果对各个指标的权重进行分析。

其中，“分数线”所占权重保持在 1.5%左右的水平，这说明被分析的专业的考研分数线较为稳定，结合考研分数的分布范围，侧面证明了热门专业的考研分数线保持高位运行。“报录比”所占权重略超过 6%，该因素受到不同专业的影响，但由于专业数据都出自十大考研最难的学校，因此不同专业间的差距总体而言维持在相对平稳的水平。“复试比例”所占权重最高，达到了 24%-26%，这是因为绝大部分专业的复试比例符合教育部指导意见，稳定在 1-1.2 范围内，而竞争激烈的专业的复试比例则高达 1.5 甚至 1.7，这一因素对专业的考研难度有很大的解释权重。

根据上述指标权重，使用 TOPSIS 评价模型计算排名，结果制表如下：

表 9:TOPIS 评价法计算结果

索引值	综合得分指数	排序
应用心理	0.56847877	1
建筑学	0.50881379	2
会计	0.28206574	3
电气工程	0.26326642	4
翻译硕士	0.25790519	5
计算机科学与技术	0.2574307	6
金融	0.22047726	7
自动化	0.18451286	8
汉语言文学	0.17444613	9
应用统计	0.16439514	10

4.2.3 问题 2 的求解

将 2019 年至 2023 年考研难度提取制表如下：

表 10:2019 年-2023 年考研难度提取制表


项	2019 年	2020 年	2021 年	2022 年	2023 年
2 因素评价得分	0.5817344	0.7359592	0.7437457	0.7253969	0.7360313
2 因素排名	5	3	1	4	2
3 因素评价得分	0.5583255	0.6838989	0.6772372	0.6022339	0.6093428
3 因素排名	6	1	2	4	3
4 因素评价得分	0.522306			0.47497	0.485751
4 因素排名	1			3	2

2023 年考研难度并不是“最难的”。多种不同因素情况的分析表明，考研难度“最难的”年份是 2020 年或 2021 年，2023 年的考研难度虽然仍保持高位，但得益于疫情结束、政策扶持、高校扩招等多方面的合力，“考研难”的余波较少地影响了 2023 年的全国研究生考试，总体维持在相对平稳的水平。

4.3 问题 3 的模型建立与求解

4.3.1 模型的建立

基于问题 2 中的研究方法和模型结果，我们认为三因素 TOPSIS 评价模型对于考研难度的评价较为准确，同时也避免了较多因素带来的数据特征模糊。因此我们采用 ARIMA 时间序列模型，对未来三年的全国研究生考试报考人数、录取人数做出了预测。



图表 12 ARIMA 时间序列介绍图


ARIMA 模型全称为自回归积分移动平均模型（Autoregressive Integrated Moving Average Model）是一种计量经济模型。ARIMA 模型可将研究对象根据时间推移的数据组成随机序列，应用一次或两次后消除其非平稳性，从而得到短期规律。通过利用数据的过去值和现在值预测其将来值，已被广泛应用在税收预测、企业未来预测等方面。

ARIMA (p, d, q) 中 AR 为自回归模型，d 为差分，q 为滑动平移模型，因此当 d=q=0 时，ARIMA 模型即为 AR 模型；当 p=d=0 时，ARIMA 模型即为 MA 模型。


ARIMA 时间序列模型的一般形式如下式所示：

$$X_t = c + \alpha_1 X_{t-1} + \alpha_2 X_{t-2} + \cdots + \alpha_p X_{t-p} + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \cdots + \beta_q \varepsilon_{t-q} \quad (16)$$

ARIMA 时间序列模型的拟合结果为：



图表 13 报考人数时间序列图



图表 14 录取人数时间序列图

ARIMA 时间序列模型的预测结果为：


表 11:ARIMA 时间序列模型的预测结果

项	2024 年	2025 年	2026 年
报考人数（万人）	532.4484	566.3365	617.38
录取人数（万人）	125.3582	132.4040	139.6375

最低国家分数线一般比较稳定，因此我们使用 2022 年的 250 分，作为未来三年预测的最低国家分数线基准。最终得到的未来三年考研难度预测结果如下：

表 12:未来三年预测得分

项	2024 年	2025 年	2026 年
预测得分	0.6214213	0.6229518	0.6147971



图表 15 未来三年预测柱状图

4.3.2 问题 3 的求解

由于未来三年的预测考研难度大致维持与 2023 年相当的难度水平，因此如何做好志愿规划、选择适宜自身的学校和专业就显得尤为重要。


首先，根据教育部《专业学位研究生教育方案(2020-2025)》文件，专业型硕士招生规模将计划扩展到硕士研究生招生总规模的 2/3，留给考研人的学术型硕士名额已不足 30 万。

表 13:全国硕士研究生招生情况（不含推免）


学位类别	22 考研招生 (不含推免) (万人)	23 考研招生 (不含推免) (万人)	人数增长 (万人)
学术性硕士	28.1472	28.4004	0.2532
专业型硕士	47.0046	47.7759	0.7713
总计	75.1518	76.1763	1.0245

2024 年的考生应该在评估各专业招生名额变化后，结合录取难度和自身目的综合评估、顺势而为。如果仅仅以上岸、提升学历等为主要目的的考生，选择报考专业型硕士能够一定程度上减轻竞争的压力，但相对地会带来更大的经济压力。

其次，根据新东方^[3]《2023 硕士研究生招生数据解读报告》，2023 年考研中艺术学、哲学、教育学、文学、管理学以及工学门类下，学术型硕士招生名额相比 2022 年考研呈现下降趋势。历史学、经济学、管理学、医学、文学门类的专业型硕士招生人数呈现上升趋势。



图表 16 23 考研学硕招生环比下降的学科门类



图表 17 23 考研专硕招生环比上升的学科门类

2024 年的考生在热门考研专业中，有可能面临更大的来自推免名额挤兑的压力，合理选择专业、切实评估跨考难度显得尤为重要。

再者，2023 年 985 工程高校的招生名额虽然总体上涨——在原本招生 126070 人的基础上，再新增 2641 人，但从工科、理科等多个学科录取名额变化分析而言，普通高等院校贡献了相对于双一流高校更多的非推免生招生名额，并且增速明显。

表 14:22 考研 vs23 考研理学学硕招生变化情况（不含推免）

理学 (学术型硕士)	招生的 二级学科 总数	22 考研招生 (人)	23 考研招生 (人)	人数增长	增长率
985 工程高校	122	7456	7427	-29	-0.4%
211 工程高校	107	12303	12143	-160	-1.3%
双一流高校	114	5377	5303	-74	-1.4%
普通高等院校	126	26151	27101	950	3.6%
科研院所	61	569	650	81	14.2%
总计	530	51856	52624	768	1.5%

2024 年的考生“逆向考研”，即本科就读 985 工程高校、211 工程高校、双一流高校的同学在考取研究生时，“降级”选择报考 39 所 985 工程高校、116 所 211 工程高校之外的普通高校的现象，也不失为一种可取的策略。以工学为例，2023 年该门类下“双非”普通高校在 64 个二级学科中新增了 1408 个招生名额，总计招收了 79417 人，以 25% 的学科占有率贡献了超过 50% 的工学专业型硕士招生名额。类似的情况也出现在法学、医学、经济学等多个“火爆”的热门专业中。


表 15:22 考研 vs23 考研工学专硕招生变化情况（不含推免）

工学 (专业型硕士)	招生的 二级学科 总数	22 考研招生 (人)	23 考研招生 (人)	人数增长	增长率
985 工程高校	58	32708	32353	-355	-1.1%
211 工程高校	61	38046	35265	-2781	-7.3%
双一流高校	48	9180	9791	611	-6.7%
普通高等院校	64	78009	79417	1408	1.8%
科研院所	17	108	164	56	51.9%
总计	248	158051	156990	-1061	-0.7%

因此 2024 年的考生在合理选择“逆向考研”策略的基础上，还应多考虑报考“特长”院校、交叉学科，寻找不同的“机遇”与“挑战”，避开“名校光环”和“热门专业”，在宏观趋势中寻找微观机会，并做出符合自身定位的、切实可行的考研决策。

最后，根据中国教育在线提供的考研原因统计数据，接近 60% 的大学生参加研究生考试是因为就业压力大，绝大多数学生并没有主动考研的动机和升学深造的愿景，加之中国就业人群中研究生学历人数占比不断提高，研究生考试将面临越来越大的难度提升、研究生学历则面临多方面挤兑造成的学历贬值。

中国教育在线统计考研原因



图表 18 考研原因统计图

2007-2019年中国就业人群中研究生学历人数占比



图表 19 2007-2019 年中国就业人群中研究生占比图

2024 年的考生选择“急流勇退”也是另一种勇气、另一种明智的选择，放弃考研、转而选择就业，三年后出现薪资倒挂反超研究生学历的同龄人的情况，如今也是屡见不鲜的。对就业形势、专业前景、就业能力等多方面因素综合评判，在合理的情况下选择放弃考研，也是 2024 年考生值得考虑的备用选项。

五、模型的分析检验

针对 ARIMA 时间序列模型，我们进行了灵敏度检验分析：



图表 20 最终差分数据自相关图 (ACF)



图表 21 模型残差自相关图 (ACF)

在差分为 2 阶时，显著性 P 值为 0.000***，水平上呈现显著性，报考人数序列为平稳的时间序列。最终差分数据偏自相关系数位于 95% 置信区间的上、下界以内，模型拟合优度 R^2 为 0.99。模型的 Q 统计量全部大于 0.1，不存在自相关性，因此模型表现优秀、基本满足要求。



图表 22 最终差分数据偏自相关图 (PACF)



图表 23 模型残差偏自相关图 (PACF)

在差分为 1 阶时，显著性 P 值为 0.000***，水平上呈现显著性，录取人数序列为平稳的时间序列。最终差分数据偏自相关系数位于 95% 置信区间的上、下界以内，模型拟合优度 R^2 为 0.987。模型的 Q 统计量全部大于 0.1，不存在自相关性，因此模型表现优秀、基本满足要求。

六、 模型的评价与改进

6.1 评估

6.1.1 优点

优点一：使用熵权法确定数据中各个因素的权重，较为客观、准确、有效。

优点二：TOPSIS 优劣解距离模型计算简单、结构合理、组内评价更有层次和逻辑、排序结果较为客观。

优点三：ARIMA 时间序列模型对关键因素的预测较为可靠、准确，进一步提升了模型的可信度，并且能够和 TOPSIS 模型相互佐证。

6.1.2 缺点

缺点一：选取出的影响因素不一定能完美适用所有不同院校、不同专业，存在一定的随机误差。

缺点二：由于数据缺失、数据有多个版本等原因，模型中使用的部分参数存在估值代替、平均值代替等情况，这给模型代入了一定误差。

6.2 改进

1. 更全面、准确地收集考研数据，有利于从不同的数据维度解释考研难度，提高模型的评价准确度。

2. 针对不同专业、不同院校的具体情况，因地制宜地选取影响因素、设计影响权重，有利于扩大模型的普适范围，贴合不同的评价场景。

七、 参考文献

- [1] ScientificPlatformServingforStatisticsProfessional2021.SPSSPRO.(Version1.0.11)[OnlineApplicationSoftware].Retrievedfrom<https://www.spsspro.com>.
- [2] ShihHS,ShyurHJ,LeeES.AnextensionofTOPSISforgroupdecisionmaking[J].Mathematical&ComputerModelling,2007,45(7):801-813.
- [3] <https://zhuanlan.zhihu.com/p/604750406>
- [4] <http://www.moe.gov.cn/>
- [5] <https://dxs.moe.gov.cn/zx/>
- [6] 王燕. 应用时间序列分析[M]. 北京: 中国人民大学出版社 2005.
- [7] S.伯恩斯坦, R.伯恩斯坦. 统计学原理.上册,描述性统计学与概率[M]. 科学出版社, 2002.

八、 附录

附录 1

介绍:支撑数据文件

1-2 因素.csv
2-3 因素.csv
3-4 因素.xlsx
4-4 因素 TOPSIS.docx
5-时间序列分析(ARIMA)_报考人数（万人）_年份.docx
6-时间序列分析(ARIMA)_录取人数（万人）_年份.docx
7-未来三年预测.docx
8-未来三年预测得分.csv
9-学校排名.csv
10-学校数据 - 描述性统计_21 年.docx
11-学校数据 - 优劣解距离法(TOPSIS) .docx
12-学校数据.xlsx
13-研究生数据 - 描述性统计_报考人数（万人）_报考增速_录取人数（万人）.docx
14-预测.xlsx
15-专业 - 描述性统计.docx
16-专业排名 - 优劣解距离法.docx
17-专业排名.xlsx
18-专业数据.xlsx

附录 2

介绍:描述性统计

1. 选择描述性分析中的描述性统计:



2. 在“选择变量”栏目中，确定待使用的变量：



3. 将“报考人数（万人）”、“报考增速”、“录取人数（万人）”、“录取增速”、“报录比”拖入变量 X：




4. 最后，开始分析：



附录 3

介绍:熵值法

1. 选择综合评价中的熵值法：



2. 在“选择变量”栏目中，确定待使用的变量：



3. 放入正向指标：



4. 放入负向指标：

放入负向指标 [定量] 变量 (正向指标+负向指标≥2)

4

录取人数 (万人)

录取增速

5. 开始分析:

重置

5

开始分析

附录 4

介绍:TOPSIS

1. 在“算法栏”栏目中, 选择 TOPSIS:

数据包络分析(DEA)

模糊综合评价

1

优劣解距离法(TOPSIS)

秩和比综合评价法(RSR)

耦合协调度

2. 在“选择变量”栏目中, 确定待使用的变量:

选择变量 ?

Q

2

选择变量

预览数据

学硕 (万人)

定量

专硕 (万人)

定量

3. 放入正向指标:

放入正向指标 [定量] 变量 (正向指标+负向指标 ≥ 2) ?

3

报考人数 (万人)

报考增速

报录比

最低国家分数线 (学硕)

推免名额 (万人)

4. 放入负向指标:

放入负向指标 [定量] 变量 (正向指标+负向指标 ≤ 2)

4

录取人数 (万人)

录取增速

5. 放入定类:

放入 [定类] 变量 (变量数≤1)

年份

5

6. “变量权重” 选择 “熵权法”:

变量权重

熵权法

▼

6

7. 开始分析:

重置

开始分析

7

附录 5

介绍:ARIMA

1. 在“算法栏”栏目中, 选择 ARIMA:

计量经济模型

时间序列分析

单位根检验(ADF)

差分分析

(偏) 自相关分析(pacf/acf)

时间序列分析(ARIMA)

GARCH模型

格兰杰因果检验

VAR向量自回归模型

季节性ARIMA模型

1

2. 在“选择变量”栏目中，确定待使用的变量：



3. 放入时间序列数据“报考人数 (万人)”：



4. 放入时间项“年份”：



5. 向后预测 3 个单位：

向后预测单位 ? 5

6. 参数自动寻优：

参数自动寻优 ☒ 6

7. 开始分析：

7

重置